MACHINE LEARNING PARA ECONOMISTAS - TRABAJO PRÁCTICO N°1

Análisis Descriptivo y Predicción de Informalidad

Fecha de entrega: 5 de noviembre de 2026

Profesor: Walter Sosa Escudero
Tutora: Luciana Ramirez

Reglas de formato y presentación

Al finalizar el trabajo práctico deben hacer un último *commit* en su repositorio de GitHub con el mensaje `Entrega final del TP` y subir el informe en PDF al buzón del TP1 en el Campus Virtual. Las dos cosas deben estar hechas antes de la fecha de entrega.

- Asegúrense de haber creado una carpeta llamada `TP1`. La carpeta debe tener el informe y el código, con los nombres `PE1333_Grupo#_TP1.pdf` y `PE1333_Grupo#_TP1.ipynb`, y la base limpia, que van a volver a usar en el TP2 y en el TP3. Todos los integrantes del grupo deben hacer al menos un *commit*.
- Se evalúa el PDF entregado en el Campus Virtual, que debe ser el mismo que el del repositorio, junto con el código de la carpeta `TP1`. Por lo que es importante que:
  - No suban el PDF al Campus Virtual hasta no haber terminado y estar seguros de que han hecho el *commit* y *push* a la versión final que quieren entregar.
  - No vuelvan a hacer *push* en la carpeta del TP después de haber entregado.
- El informe debe ser entregado en formato PDF, con los gráficos e imágenes en este mismo archivo. Puede tener una extensión máxima de 12 páginas. Se espera una buena redacción en la resolución.
- Entreguen el código con los comandos utilizados, identificando claramente a qué inciso corresponde cada comando.
- Las herramientas de inteligencia artificial pueden utilizarse como **apoyo** en la elaboración del trabajo. No obstante, en caso de ser utilizadas, deberán ser **debidamente referenciadas**, indicando de manera breve y clara **qué herramienta se usó**, **para qué se la empleó** y **en qué parte del trabajo** intervino. La utilización de IA no reemplaza la comprensión ni la autoría del grupo sobre los contenidos presentados, por lo que cada grupo es plenamente responsable por la calidad, veracidad y coherencia de la entrega final.

Para realizar este trabajo, utilicen las bases individual y de hogares de la EPH del primer trimestre de 2026, sin limpiar. Las pueden descargar de la página de INDEC[1], donde también está el cuadernillo de Diseño de Registro y Estructura de la EPH con la descripción de las variables.

Parte I: Analizando la base

1. Utilizando la base individual, conserven solamente a los ocupados y construyan la variable dependiente `informal` a partir de la variable `EMPLEO` de INDEC, que clasifica a todos los ocupados en formales (1) e informales (2). Las observaciones con código 9 quedan afuera. Seleccionen al menos quince variables socioeconómicas que consideren relevantes para predecir la informalidad y justifiquen su elección.[2] Limpien los valores sin sentido reemplazándolos por `NaN`.[3]

   Las variables que forman parte de la definición de `EMPLEO` no pueden incluirse en la matriz X. Son `EMPLEO`, `SECTOR`, el descuento jubilatorio (`PP07H`), los aportes y beneficios de los asalariados (`PP07I`, `PP07G1` a `PP07G4`, `PP07G_59`, `PP07K`, `PP07L`) y el registro de los independientes (`PP05I`, `PP05J`, `PP05K`). Expliquen en dos o tres oraciones por qué se descartan estas variables. (*Hint:* un predictor que forma parte de la definición de y da un ajuste casi perfecto que no se sostiene fuera de la muestra.)

2. Construyan al menos tres variables que no estén en la base pero que sean relevantes para predecir la informalidad, y justifiquen brevemente cada una. Por ejemplo, `edad2` (edad al cuadrado), `educ` (años de educación, usando inteligentemente `CH12`, `CH13` y `CH14`), `horastrab` (total de horas trabajadas, como la suma de las horas en la ocupación principal y en otras ocupaciones, `PP3E_TOT + PP3F_TOT`), `nhogar` (número de miembros del hogar, usando inteligentemente `CODUSU`, `NRO_HOGAR` y `COMPONENTE`) o la proporción de miembros del hogar que trabajan.[4]

3. Muestren un heatmap de valores faltantes de su matriz X. ¿Qué variables concentran los faltantes? Expliquen qué decidieron hacer con ellos. Luego, creen una tabla de diferencia de medias entre formales e informales para las variables de su matriz X. Comenten la tabla.[5]

4. Dividan las observaciones en una base de prueba (test) y una de entrenamiento (train) utilizando el comando `train_test_split`. La base de entrenamiento debe comprender el 70 % de los datos, y la semilla a utilizar (random state instance) debe ser 444. Establezcan a `informal` como su variable dependiente (vector y). El resto de las variables seleccionadas y creadas serán las variables independientes (matriz X). Recuerden agregar la columna de unos (1) para el intercepto. Guarden la base limpia en el repositorio.

[1] `https://www.indec.gob.ar`, sección Bases de datos de la Encuesta Permanente de Hogares.

[2] Aclaración: variables identificadoras como `CODUSU`, `NRO_HOGAR` y `COMPONENTE` no son variables predictoras de informalidad. Así que creen su matriz X inteligentemente. Por ejemplo, si incluyen años de educación, no incluyan las dummies de nivel educativo, ya que una está en función de la otra.

[3] Ayuda: la base se lee con `pd.read_excel()`. Los códigos de no respuesta se pueden reemplazar con `.replace(9, np.nan)`. Revisen en el Diseño de Registro qué código corresponde a cada variable.

[4] Si alguna de las variables que quieren construir está en la base de hogares (`usu_hogar_T126`), únanla a la base individual. Asegúrense de estar usando las variables `CODUSU` y `NRO_HOGAR` para el merge. Ayuda: `pd.merge(individual, hogar, on=["CODUSU", "NRO_HOGAR"], how="left")`.

[5] Ayuda: el heatmap se puede hacer con `sns.heatmap(X.isna())` de la librería `seaborn`. Las variables categóricas se pasan a dummies con `pd.get_dummies()`, y el test de diferencia de medias está en `scipy.stats.ttest_ind()`.

Parte II: Regresión logística y análisis discriminante

5. Estimen una regresión logística usando `X_train`. Exporten una tabla con (i) los coeficientes estimados para cada variable, (ii) los errores estándar y (iii) los *odds ratios*. Interpreten al menos dos coeficientes, prestando atención a la diferencia entre el signo del coeficiente y la magnitud del efecto sobre la probabilidad.

6. Grafiquen la probabilidad de ser informal $\widehat{P}(Y = 1 \mid X)$ (en el eje vertical) y alguna característica numérica (en el eje horizontal). Comenten dicho gráfico y la variable seleccionada.

7. Estimen un modelo de análisis discriminante lineal (LDA) usando `X_train`. ¿Qué supone LDA sobre la distribución de X dentro de cada clase que la regresión logística no supone? Comenten brevemente si ese supuesto es razonable para las variables de su matriz X.

Parte III: Vecinos cercanos

8. Estimen vecinos cercanos (KNN) con $K = \{10, 50, 100\}$ usando `X_train`. Expliquen en 2-3 oraciones cómo la elección de K se relaciona con el trade-off sesgo-varianza y qué ocurre en los extremos $K = 1$ y $K = n$.

9. Para obtener el K óptimo usando cross-validation, dividan `X_train` en 5 partes. Muestren cómo eligen el número óptimo de vecinos cercanos (K) a través del gráfico de *accuracy* en cada K. La grilla debe llegar hasta valores de K en los que la curva deje de mejorar. Llámenle a este modelo KNN con K-CV. (*Hint:* estandaricen las variables antes de estimar, utilizando las medias y los desvíos de la base de entrenamiento, ya que KNN usa distancias.)

Parte IV: Desempeño de modelos y elección

10. Comparen el desempeño de predicción de informalidad en la base de testeo de la regresión logística, el LDA y el KNN con K-CV. Muestren la matriz de confusión (con umbral $p > 0{,}5$), la curva ROC de los tres modelos y dos métricas más vistas en clase, e interpreten los resultados.

11. Supongan que la Secretaría de Trabajo está interesada en identificar a trabajadores informales para dirigir los recursos de un programa de formalización laboral con presupuesto acotado. Discutan qué modelo de clasificación elegirían para asignar dichos recursos escasos y con qué umbral. Justifiquen su respuesta en términos del costo relativo de los dos errores, dejar afuera a un informal o asignarle recursos a alguien que ya es formal, utilizando los números que reportaron en el inciso anterior.