MACHINE LEARNING PARA ECONOMISTAS - TRABAJO PRÁCTICO N°2

Regularización y árboles
Informalidad laboral en la EPH

Fecha de entrega: 26 de noviembre de 2026

Profesor: Walter Sosa Escudero
Tutora: Luciana Ramirez

Reglas de formato y presentación

Al finalizar el trabajo práctico deben hacer un último *commit* en su repositorio de GitHub con el mensaje `Entrega final del TP` y subir el informe en PDF al buzón del TP2 en el Campus Virtual. Las dos cosas deben estar hechas antes de la fecha de entrega.

- Asegúrense de haber creado una carpeta llamada `TP2`. La carpeta debe tener el informe y el código, con los nombres `PE1333_Grupo#_TP2.pdf` y `PE1333_Grupo#_TP2.ipynb`, y la base que usaron, si agregaron variables respecto del TP1. Todos los integrantes del grupo deben hacer al menos un *commit*.
- Se evalúa el PDF entregado en el Campus Virtual, que debe ser el mismo que el del repositorio, junto con el código de la carpeta `TP2`. Por lo que es importante que:
  - No suban el PDF al Campus Virtual hasta no haber terminado y estar seguros de que han hecho el *commit* y *push* a la versión final que quieren entregar.
  - No vuelvan a hacer *push* en la carpeta del TP después de haber entregado.
- El informe debe ser entregado en formato PDF, con los gráficos e imágenes en este mismo archivo. Puede tener una extensión máxima de 12 páginas. Se espera una buena redacción en la resolución.
- Entreguen el código con los comandos utilizados, identificando claramente a qué inciso corresponde cada comando.
- Las herramientas de inteligencia artificial pueden utilizarse como **apoyo** en la elaboración del trabajo. No obstante, en caso de ser utilizadas, deberán ser **debidamente referenciadas**, indicando de manera breve y clara **qué herramienta se usó**, **para qué se la empleó** y **en qué parte del trabajo** intervino. La utilización de IA no reemplaza la comprensión ni la autoría del grupo sobre los contenidos presentados, por lo que cada grupo es plenamente responsable por la calidad, veracidad y coherencia de la entrega final.

El objetivo de este trabajo es evaluar la predicción de informales utilizando técnicas de regularización y árboles de decisión. La idea es que usen las variables socioeconómicas que limpiaron en el TP1, con la misma partición en entrenamiento y testeo (70 %, `random_state = 444`). Es decir, la base deberá contar con al menos quince variables. Si piensan que hay más variables que son relevantes para predecir la informalidad, las pueden incluir.

Aclaración: en la Parte I, estimen los modelos sin la columna de unos que agregaron en el TP1 y estandaricen las variables antes de estimar, usando las medias y los desvíos del entrenamiento.

Parte I: Regresión logística con regularización, Ridge y LASSO

1. Grafiquen en dos paneles distintos los coeficientes de la penalidad de LASSO y Ridge para la grilla de parámetros de penalidad $\lambda = 10^n$ con $n \in \{-5, -4, -3, \ldots, 4, 5\}$ e interpreten la regularización con cada penalidad. (*Hint:* en la función `LogisticRegression` la opción `C` es la inversa de la fuerza de penalidad, en lugar de `alpha`. Según el tamaño de su matriz, se recomienda probar con distintas opciones de `solver` para el uso eficiente computacional.)

2. Usando `LogisticRegressionCV` y dividiendo la base en 5 partes (5-fold), elijan la penalidad óptima λ^{cv} en la grilla mencionada arriba. ¿Qué λ^{cv} seleccionaron en cada caso? Generen box-plots mostrando la distribución del error de predicción para cada λ. Cada box debe corresponder a un valor de λ y contener como observaciones el error de clasificación de validación para cada partición. Opcional: para la regularización LASSO, generen un gráfico de puntos conectados con la proporción de variables ignoradas por el modelo en función de λ, es decir, la proporción de variables para las cuales el coeficiente asociado es cero.

3. Estimen una regresión logística usando `X_train` sin penalidad, con penalidad L1 y con penalidad L2, siendo la penalidad la λ^{cv} óptima elegida en el inciso anterior. Exporten una tabla con las siguientes columnas: (i) los coeficientes estimados para cada variable sin penalidad, (ii) los coeficientes con penalidad L1 y (iii) los coeficientes con penalidad L2. Interpreten los resultados de la tabla y contesten: ¿cómo son los coeficientes de la regularización con respecto a logit sin penalidad? ¿La penalidad L2 elimina variables de las que incluyeron en su matriz `X_train`?

Parte II: Árboles

4. Estimen un árbol de decisión podado (CART) eligiendo el hiperparámetro de costo de complejidad del árbol (`ccp_aplha`) con 10-fold cross-validation. En un gráfico de línea, muestren el error de clasificación en función de la grilla de valores que usaron para `ccp_aplha`. Comenten los resultados.

5. En un panel A, muestren el gráfico del árbol podado que obtuvieron e interprétenlo. En un panel B, muestren en un gráfico la importancia de cada uno de los predictores. ¿Podría decirse que los coeficientes de las variables menos importantes son los que LASSO "achicó" a cero?

Parte III: Comparación entre métodos

6. Computen la matriz de confusión (con umbral $p > 0{,}5$), la curva ROC y las dos métricas que utilizaron en el TP1. Comparen el desempeño de la regresión logística sin penalidad y el KNN con K-CV (ambos del TP1), el logit con penalidad LASSO y Ridge, y el árbol de decisión. Comenten los resultados. ¿Qué pueden decir del trade-off entre comunicación de los resultados y performance predictiva? En este caso, ¿hay una ventaja por utilizar un método no lineal? Incorporen dentro de la justificación ($1 - \textit{accuracy}$) para argumentar.

7. Recuerden que la Secretaría de Trabajo está interesada en identificar a trabajadores informales para dirigir los recursos de un programa de formalización laboral con presupuesto acotado. ¿Cambió su respuesta del TP1 con respecto a cuál es el "mejor" modelo para asignar recursos escasos?