

Regresión y predicción

Tutorial 2 – Test de lectura, APIs y web scraping

Luciana Azul Ramirez

PE1333 – Machine Learning para Economistas
Universidad de San Andrés

8 de octubre de 2026

Parte I

Test de lectura

$$\underbrace{ECM(\hat{\beta}) = E(\hat{\beta} - \beta)^2}_{\text{un estimador contra un parámetro}}$$

$$\underbrace{Err(\hat{Y}) = E(Y - \hat{Y})^2}_{\text{dos variables aleatorias}}$$

Test de lectura

T1.4. ¿Cuál es la principal diferencia entre estimar y predecir?

T1.15. ¿Por qué en econometría no aparece el ECM?

$$\widehat{Err}_{MT}(\hat{Y}) = \sum_{i \in MT} (Y_i - \hat{Y}_i)^2$$

- La muestra se parte en dos conjuntos disjuntos: se entrena en uno y se mide el error en el otro.
- Reservar observaciones para evaluar tiene un costo.
- No hay una forma obvia de elegir el corte, que es el problema que resuelve cross validation.

Test de lectura

T1.3. ¿Un estimador de MCO que usa menos observaciones que las originales es más ineficiente que si las usa todas?

	$Y_i = 0$	$Y_i = 1$
$\hat{Y}_i = 0$	vn	fn
$\hat{Y}_i = 1$	fp	vp

$$R(i) = (1 - p) \lambda(i, 0) + p \lambda(i, 1)$$

$$p = P(Y = 1 | X)$$

- $\lambda(i, j)$ castiga quedar en la casilla (i, j) , y se elige la acción de menor riesgo esperado.
- Con penalidad 0-1, $R(1) < R(0)$ equivale a $p > 1/2$.

Test de lectura

T2.5. ¿La regla de clasificación de Bayes ata el problema de predecir Y al de conocer su probabilidad de ocurrencia?

T2.6. ¿Predecir el evento más probable es consecuencia de creer que falsos positivos y falsos negativos se penalizan igual?

- El clasificador de Bayes tiene dos supuestos: que los dos castigos valen lo mismo, y que lo único que importa es el valor esperado.
- Levantar el primero mueve el umbral, y deja de estar en $1/2$.

Test de lectura

T2.3. En derecho se es inocente hasta que se demuestre lo contrario. ¿Cómo es $\lambda(i, j)$ en ese caso?

T2.4. Si $Y = 1$ es que la película es buena, ¿cómo es la función de pérdida de alguien que no soporta perderse películas buenas?

$$p = P(Y = 1 \mid X)$$

- El clasificador de Bayes deja el problema reducido a estimar p . Hay tres modelos para eso, siempre en el caso binario: regresión logística, vecinos cercanos y análisis discriminante.
- Los tres estiman lo mismo. Lo que cambia son los supuestos.

¿Por qué no $p = X\beta$ directamente?

Se sale del rango $(0, 1)$. Y logit y análisis discriminante se generalizan al caso de P categorías no ordenadas.

Parte II

Are Online and Offline Prices Similar?

Cavallo (2017), *American Economic Review* 107(1), pp. 283–303

- Los precios de internet ya se usan para medir inflación y para investigar, pero las compras online son menos del 10 % de las transacciones minoristas.
- Nadie había comparado, a escala, el precio del sitio contra el de la góndola del mismo retailer.

La pregunta

Si una oficina de estadística reemplaza al encuestador que camina hasta el local por un programa que lee el sitio, ¿está midiendo el mismo precio?

Cómo se construye la base

- **Offline:** 323 personas contratadas por plataformas de *crowdsourcing* (Amazon Mechanical Turk, Elance y UpWork) escanean el código de barras en el local, cargan el precio y fotografían la etiqueta.
- **Online:** un *scraper* hecho a medida busca ese mismo código de barras en el sitio del retailer y levanta el precio online, dentro de los siete días.
- 56 retailers, 10 países, Argentina entre ellos. 24.000 productos y 38.000 observaciones, entre diciembre de 2014 y marzo de 2016.

Lo que hace comparables a las dos mitades

El código de barras. Sin una clave que identifique al mismo producto en los dos canales, la comparación no existe.

Qué encuentra el paper

- Los precios son **idénticos el 72 %** de las veces. Cuando difieren, el precio online es en promedio 4 % más bajo.
- La dispersión es grande: 42 % en Brasil contra 91 % en Canadá y Reino Unido. Por sector, 25 % en artículos de oficina contra 92 % en ropa.
- Los cambios de precio tienen frecuencia y tamaño parecidos, pero solo el 19 % ocurre en la misma semana en los dos canales.

Lo que buscó y no encontró

El precio online no cambia según la dirección IP desde la que se entra, ni cuando el programa visita la misma página muchas veces.

- Para las oficinas de estadística, la web funciona como tecnología de recolección: devuelve el mismo precio que caminar hasta el local, a una fracción del costo.
- Para quien investiga, los precios online son una fuente válida, con la advertencia de controlar por retailer y por sector.

- Cavallo, A. (2017). Are Online and Offline Prices Similar? Evidence from Large Multi-Channel Retailers. *American Economic Review*, 107(1), 283–303.
- Sosa Escudero, W. (2026). *Regresión y predicción*. Clase 1, parte 2. PE1333, UdeSA.
- Sosa Escudero, W. (2026). *Regresión y predicción*. *Test de lectura*. PE1333, UdeSA.
- James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*, cap. 3.