

Predecir y explicar

Tutorial 1 – Repaso de la Clase 1 e introducción a Python

Luciana Azul Ramirez

PE1333 – Machine Learning para Economistas
Universidad de San Andrés

1 de octubre de 2026

Parte I

Repaso de la Clase 1

$$Y = X\beta + u, \quad \hat{\beta} = (X'X)^{-1}X'Y, \quad \hat{Y}_i = X_i'\hat{\beta}$$

- El modelo viene dado.
- El objetivo es estimar β y hacer inferencia sobre β .
- Gauss-Markov es condicional: *si* valen los supuestos, *entonces* $\hat{\beta}$ es MELI.
- Y si $\hat{\beta}$ es insesgado y de varianza mínima, $\hat{Y}_i$ también lo es, con $V(\hat{Y}_i) = \sigma^2 X_i'(X'X)^{-1}X_i$.

Lo que esto significa

En el mundo clásico predecir bien es un subproducto de estimar bien.

- En *machine learning* lo que se compara pasa a ser Y contra $\hat{Y}$.
- **Predecir** es asignar un valor a algo que no se observa. *Pronosticar* es el caso particular en que ese valor corresponde a un período futuro.
- El modelo deja de venir dado por la teoría y pasa a aprenderse de los datos.

Tres preguntas

Predecir qué hogares son pobres sin esperar el próximo relevamiento. Medir la inflación con precios publicados en internet. Estimar el efecto de un impuesto sobre las ventas.

$$ECM(\hat{\beta}) \equiv E(\hat{\beta} - \beta)^2 = \text{Sesgo}^2(\hat{\beta}) + V(\hat{\beta})$$

- Se equivoca por estar descentrado respecto de la verdad, o por ser disperso alrededor de su propio centro.

Test de lectura

6. *¿El ECM mide cuán lejos está el estimador de su valor esperado?*
7. *Si un estimador es insesgado, ¿el ECM es igual a la varianza?*

$$Err(\hat{Y}) \equiv E(Y - \hat{Y})^2 = \underbrace{ECM(\hat{Y})}_{\text{reducible}} + \underbrace{\sigma^2}_{\text{irreducible}} = \text{Sesgo}^2(\hat{Y}) + V(\hat{Y}) + \sigma^2$$

- A diferencia del ECM, acá se comparan dos variables aleatorias. Son dos razones distintas para equivocarse: no conocer f , y no observar u .
- El σ^2 no lo baja ningún método. Es el piso de cualquier predicción.
- Sobre el primer término sí se puede decidir, y ahí está todo el margen.

Test de lectura

9. ¿Qué diferencia hay entre el ECM y el error de pronóstico?
12. ¿Minimizar el error de pronóstico equivale a minimizar el ECM?

Un estimador sesgado con menor ECM que MCO

Un solo regresor, variables normalizadas, supuestos clásicos. Sea

$$\hat{\beta}_r = \frac{\hat{\beta}}{1 + \lambda}, \quad \lambda \geq 0$$

- Es MCO achicado hacia cero.
- Es el **ejercicio 19** del test de lectura: obtener sesgo, varianza y ECM de los dos estimadores, y mostrar que existe un λ con menor ECM que MCO.

Test de lectura

El óptimo es $\lambda^* = \sigma^2/(n\beta^2)$, y ahí $ECM(\hat{\beta}_r)/ECM(\hat{\beta}) = \beta^2/(\beta^2 + \sigma^2/n) < 1$ para cualquier β , σ^2 y n . Preferir estimadores insesgados es una restricción autoimpuesta, no un resultado.

Y λ^* depende de β

Que es lo que no conocemos. Cross validation.

$$\widehat{Err}(\hat{Y}) = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_i e_i^2, \quad R^2 = 1 - \widehat{Err}(\hat{Y})/SCT$$

- MCO minimiza el error **dentro** de la muestra, que es lo mismo que maximizar el R^2 .
- El objetivo de este curso es minimizar el error **fuera** de la muestra.
- Que $\hat{f}$ funcione bien adentro no implica que funcione afuera. Eso es sobreajuste.

Test de lectura

16. *¿Por qué en econometría no hay muestra de entrenamiento y de evaluación?*

Parte II

The Parable of Google Flu: Traps in Big Data Analysis

Lazer, Kennedy, King y Vespignani (2014), *Science* 343, pp. 1203–1205

A Bright Idea for Measuring Economic Growth

Henderson, Storeygard y Weil (2011), *AER* 101(3), pp. 194–199

Google Flu Trends contra un modelo trivial

- Ginsberg et al. (2009, *Nature*): **50 millones** de términos, **1152** observaciones de región y semana, **45** elegidos.
- Febrero de 2013: **más del doble** que el CDC.
- Temporada 2011–2012: se pasó **más del 50 %**.
- **100 de 108 semanas** sobreestimando.

Modelo	Error absoluto medio
Google Flu Trends	0,486
CDC rezagado, con estacionalidad	0,311
GFT + CDC rezagado	0,232

Los errores no son ruido

Autocorrelación temporal y estacionalidad.

Soberbia del Big Data: sustituir en lugar de complementar

- $p = 50$ millones contra $n = 1152$.
- Decidir a mano qué términos cuentan.
- “Tengo frío” es tan compatible con gripe como con invierno.

Dinámica de los algoritmos: el proceso generador cambia

- 86 cambios al buscador en junio y julio de 2012.
- Sugerencias de búsqueda y diagnósticos ante síntomas.
- Prevalencia relativa: el índice se mueve sin más enfermos.

En parte detector de gripe, en parte detector de invierno.

Qué concluye el paper

- Los **45 términos** nunca se publicaron.
- La visión original era correcta y hay señal valiosa.
- *All data revolution*, no *big data revolution*.
- GFT sirve para la granularidad geográfica que el CDC no da.
- Google dio de baja el acceso público en **agosto de 2015**.

Ninguna de las dos fuentes alcanza sola.

El caso opuesto: luces nocturnas y PBI

- Henderson, Storeygard y Weil (2011), *AER* 101(3). 118 países de ingreso bajo y medio, 1992–2008.
- La luz visible desde el espacio refleja densidad poblacional e ingreso per cápita.
- Satélites meteorológicos de la fuerza aérea de Estados Unidos, 181 millones de celdas de grilla de unos $0,86 \text{ km}^2$.
- Separan países por la calificación de capacidad estadística del Banco Mundial: 30 con 0 a 3, 88 con 4 a 10.

Para qué sirve

Para países con estadísticas de ingreso poco confiables, y para medir donde no hay cuentas nacionales: ciudades, regiones, áreas que cruzan fronteras.

Cómo combinan las dos fuentes

Dos medidas con error de un y que nadie observa:

$$\underbrace{z = y + \varepsilon_z}_{\text{cuentas nacionales}}, \quad V(\varepsilon_z) = \sigma_z^2 \quad \underbrace{x = \beta y + \varepsilon_x}_{\text{luces}}, \quad V(\varepsilon_x) = \sigma_x^2$$

$$\hat{y} = \lambda z + (1 - \lambda)\hat{z}$$

- Los dos errores no están correlacionados, y de sus varianzas sale el peso.
- Países con peor capacidad estadística: λ entre 0,48 y 0,56.
- Myanmar: de **10 %** anual a **6,5 %**. Burundi: de $-0,71 \%$ a $+1,1 \%$.

- Lazer, D., Kennedy, R., King, G. y Vespignani, A. (2014). The Parable of Google Flu. *Science*, 343(6176), 1203–1205.
- James, Witten, Hastie, Tibshirani y Taylor (2023). *ISLP*, caps. 1 y 2.
- Sosa Escudero, W. (2021). *Big data*, cap. 1, pp. 23 a 33, y cap. 3, pp. 76 a 85.
- Henderson, J. V., Storeygard, A. y Weil, D. N. (2011). A Bright Idea for Measuring Economic Growth. *American Economic Review*, 101(3), 194–199.
- Athey, S. (2017). Beyond prediction: Using big data for policy problems. *Science*, 355(6324), 483–485.