Clasificación

Tutorial 3 – Tres formas de estimar p y análisis ROC

Luciana Azul Ramirez

PE1333 – Machine Learning para Economistas
Universidad de San Andrés

15 de octubre de 2026

Parte I

Tres formas de estimar p

Regresión logística

$$p = \frac{e^z}{1+e^z}, \quad z \equiv X\beta \qquad \Longleftrightarrow \qquad \ln\left(\frac{p}{1-p}\right) = X\beta$$

- Es una función no lineal de un objeto lineal, con asíntotas en 0 y 1.
- $p/(1-p)$ es el *odds*: cuántas veces es más probable que el evento ocurra a que no ocurra.
- $\beta_k = \partial \ln[p/(1-p)]/\partial X_k$. El coeficiente mueve el logaritmo del *odds*, no la probabilidad.

Test de lectura

T2.9. Si X es el promedio de carrera e Y indica si una persona fue admitida a un posgrado, ¿qué interpretación tiene $\beta = 1$ en términos de odds ratio? ¿Y $\beta = 0{,}6$?

Máxima verosimilitud

$$L(\beta; y) = \prod_{y_i=1} p_i \prod_{y_i=0} (1 - p_i), \qquad p_i = \frac{e^{X_i\beta}}{1 + e^{X_i\beta}}$$

- Roles cambiados: la muestra queda fija y lo que se mueve es β.
- $\hat{\beta}$ es el valor que hace más probable la muestra observada.
- En el logit no hay forma cerrada. Maximizar es un problema computacional.

Test de lectura

T2.11. ¿Por qué la verosimilitud de la muestra es el producto de las verosimilitudes de cada uno de sus elementos?

Clasificar y discriminar

$$p > \frac{1}{2} \iff \ln\left(\frac{p}{1-p}\right) > 0 \iff \beta_1 + \beta_2 X > 0$$

- **Clasificación**: ocurre en el espacio de las probabilidades.
- **Discriminación**: ocurre en el espacio de X.
- $\beta_1 + \beta_2 X$ es la función de discriminación del logit, y es lineal. Con dos predictores la frontera es una recta, con más es un hiperplano.

Test de lectura

T3.7. V o F: predecir $Y = 1$ es equivalente a verificar que el logaritmo del odds de esa observación es mayor que cero.

T3.8. En un modelo de credit scoring, $p = F(\beta_1 + \beta_2 X)$ con X la edad. Si $\beta_1 = -50$ y $\beta_2 = 2$, ¿a partir de qué edad se otorga el crédito?

Vecinos cercanos

$$\hat{p}(x_0) = \frac{1}{K} \sum_{j \in \mathcal{N}_0} 1[Y_j = 1]$$

- $\mathcal{N}_0$ son los K puntos de la muestra más cercanos a x_0 según la distancia $d(X_i, x_0)$.
- Se predice con la regla de Bayes, por voto por mayoría.
- No impone una forma para p. K es un hiperparámetro y se fija antes de estimar.
- Con más de dos categorías se generaliza sin esfuerzo.

Test de lectura

T3.11. Se quiere predecir si una persona mira una serie, una película o un documental, y el predictor es el ingreso. ¿Cómo funciona vecinos cercanos con $K = 20$ para alguien que gana 100.000 por mes?

$$p = \frac{\kappa f_1(x)}{\kappa f_1(x) + (1-\kappa) f_0(x)}$$

- Es la regla de Bayes: arma $P(Y = 1 \mid X)$ a partir de la probabilidad dada vuelta, $f_j(x) \simeq P(X = x \mid Y = j)$.
- $\kappa \equiv P(Y = 1)$ es la probabilidad no condicional. Se estima con la proporción de unos en la muestra.
- Se estiman κ, f_1 y f_0, se reemplazan y se usa el clasificador de Bayes.

Test de lectura

T3.2. En un modelo de credit scoring, Y indica si la persona pagó el crédito y el único predictor X es la edad. Intuitivamente, ¿qué es $f(X = 35 \mid Y = 1)$?

Discriminación lineal y cuadrática

Un predictor, y $X \mid Y = j \sim N(\mu_j, \sigma_j^2)$ para $j = 0, 1$:

$$\ln\left(\frac{p}{1-p}\right) = \gamma_1 + \gamma_2 x \qquad \text{si } \sigma_0^2 = \sigma_1^2$$

- Se parte la muestra según Y y se estiman μ_0, μ_1, σ_0^2 y σ_1^2 en cada parte.
- Con igual varianza la función de discriminación es lineal. Con varianzas distintas es cuadrática.
- Logit estima γ_1 y γ_2 directamente. Análisis discriminante los arma con κ, μ_j y σ_j^2.

Test de lectura

T3.9. ¿Por qué la función de discriminación es lineal cuando las varianzas son iguales?

T3.6. Si uno de los predictores es el género de la persona, ¿cuál es el problema con análisis discriminante?

Parte II

Análisis ROC

La curva ROC

$$\hat{Y}_i = 1[p_i > c], \qquad tvp = \frac{vp}{P}, \qquad tfp = \frac{fp}{N}$$

- $P = \sum Y_i$ son los positivos y $N = \sum(1 - Y_i)$ los negativos. Las dos tasas se leen dentro de cada grupo verdadero.
- Bayes es $c = 0{,}5$, el caso simétrico. Con pérdida asimétrica, $c \neq 0{,}5$.
- Mover c cambia cuántas predicciones positivas hay. Reducir un error aumenta el otro.
- La curva ROC es el par (tfp, tvp) para todos los valores de $c \in [0, 1]$.

Test de lectura

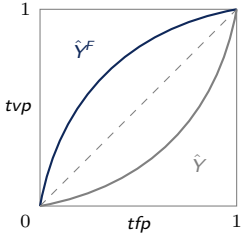
T3.14. V o F: el origen de la curva ROC corresponde a $c = 0$.

T3.15. ¿Por qué la curva ROC tiene pendiente positiva?

El clasificador invertido

$$\hat{Y}_i^F \equiv 1 - \hat{Y}_i \quad \Longrightarrow \quad tfp - tvp = tvp^F - tfp^F$$

- La recta de 45° es la línea de azar: $tvp = tfp$.
- La curva del invertido queda siempre por encima de la diagonal ssi la original está siempre por debajo.



Comparar clasificadores

- La curva ideal sube pegada al eje vertical hasta $tvp = 1$ con $tfp = 0$.
- El área bajo la curva (AROC) es una suerte de R^2 del clasificador.
- Si una curva queda siempre por debajo de otra, ese clasificador está dominado.
- Para elegir c, se fija un máximo tolerable para tfp.

Test de lectura

T3.20. V o F: si para los mismos datos de entrenamiento la curva ROC de logit está siempre por debajo de la de vecinos cercanos, no tiene sentido usar logit.

T3.21. Si las curvas ROC de dos clasificadores se cruzan, ¿cuál conviene usar?

Referencias

- Sosa Escudero, W. (2026). *Clasificación*. Clase 2. PE1333, UdeSA.
- Sosa Escudero, W. (2026). *Análisis ROC*. Clase 2, parte 2. PE1333, UdeSA.
- Sosa Escudero, W. (2026). *Clasificación I. Test de lectura*. PE1333, UdeSA.
- James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*, cap. 4, secciones 4.1 a 4.6.