Cross validation

Tutorial 4 – Cómo medir el error fuera de la muestra

Luciana Azul Ramirez

PE1333 – Machine Learning para Economistas
Universidad de San Andrés

22 de octubre de 2026

Dentro y fuera de la muestra

$$\widehat{err} = \frac{1}{n}\sum_{i=1}^{n} L(Y_i, \hat{Y}_i) \qquad Err_T = E\left[L(Y, \hat{Y}) \mid T\right]$$

- $\widehat{err}$ es el error en la muestra de entrenamiento. Err_T es el error en una muestra de testeo T, que el modelo no vio.
- Más complejidad siempre baja $\widehat{err}$. Lo que interesa es Err_T.
- El problema es cómo elegir T sin gastar datos.

Test de lectura

T4.10. ¿Por qué el R^2 no funciona para medir la capacidad de pronóstico fuera de la muestra?

T4.11. En el gráfico de sobreajuste, ¿cómo sería un gráfico del R^2 en función del grado del polinomio ajustado?

El enfoque de validación

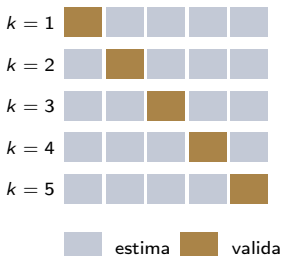
- Se parte la base de entrenamiento en dos: se estima con una parte y se mide el error en la otra.
- Se elige la complejidad con menor error en la parte de validación.
- Tiene dos problemas:
  - el resultado depende de la partición,
  - cada modelo se estima con menos datos.

K-fold cross validation

1. Se parten los datos al azar en K bloques.
2. Se estima dejando afuera uno de los bloques.
3. Se calcula el error en el bloque que quedó afuera.
4. Se repite para cada uno de los K bloques.

$$CV(\hat{f}) = \frac{1}{n}\sum_{i=1}^{n} L\left(Y_i, \hat{Y}_{-k}(x_i)\right)$$

$\hat{Y}_{-k}(x_i)$ es la predicción para i hecha con el modelo estimado sin el bloque k, que es el bloque de i.



Los extremos

- $K = 1$: no hay datos para validar.
- $K = n$: *leave one out*. Se deja afuera una observación por vez y se estima el modelo n veces, cada una con $n - 1$ datos.
- En general, el modelo se estima K veces, cada una con $n(K - 1)/K$ datos.

Test de lectura

T4.14. V o F: en cross validation, cuando $K = n$ el modelo es estimado n veces.

Elección de K

- K chico: cada modelo se estima con pocos datos, y el error queda sobreestimado.
- K grande: los K modelos se estiman casi con los mismos datos y se parecen mucho entre sí. El promedio de sus errores es muy variable, y además es caro.
- La regla es $K = 5$ o $K = 10$ (Kohavi, 1995).

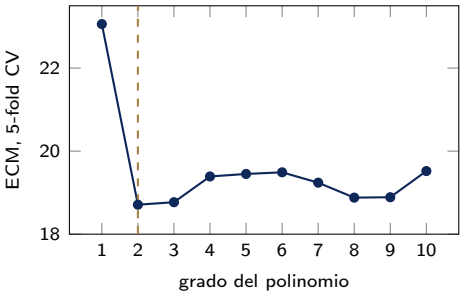
Test de lectura

T4.12. En cross validation, ¿cuál es el problema de usar un K muy pequeño y uno muy grande?

Cross validation para elegir la complejidad

$$CV(\hat{f}, \alpha) = \frac{1}{n} \sum_{i=1}^{n} L\left(Y_i, \hat{Y}_{-k}(x_i, \alpha)\right)$$

- α indexa la complejidad: el grado del polinomio, la cantidad de vecinos.
- Se calcula $CV(\hat{f}, \alpha)$ en una grilla de valores de α y se elige el mínimo.

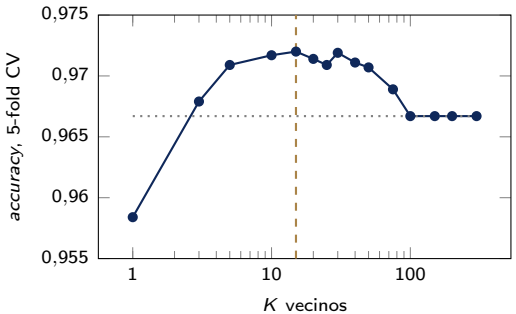


Test de lectura

T4.15. Explicá intuitivamente cuál es el procedimiento usado para hacer el gráfico de la elección del grado del polinomio.

Elegir K en vecinos cercanos

- En el Tutorial 3 el $K = 25$ estaba fijado de antemano.
- Se elige igual que el grado del polinomio, maximizando el *accuracy* de 5-fold CV.
- Las variables se estandarizan con la media y el desvío de entrenamiento.
- La grilla tiene que llegar hasta donde la curva deja de mejorar.



El modelo final

- Los K modelos de cross validation sirven para medir el error, no para predecir.
- Con el α elegido se estima una vez más, con toda la base de entrenamiento.
- La base de testeo se usa una sola vez, al final, para evaluar ese modelo.

Test de lectura

T4.13. Para hacer cross validation estimamos el modelo K veces. Una idea es reemplazar el estimador inicial por el promedio de los K modelos estimados en el proceso. ¿Por qué esta estrategia en general no funciona?

Referencias

- Sosa Escudero, W. (2026). *Cross validation*. Clases 4 y 5. PE1333, UdeSA.
- Sosa Escudero, W. (2026). *Overfit, cross validation y bootstrap. Test de lectura*. PE1333, UdeSA.
- James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*, cap. 5, sección 5.1, y cap. 6, sección 6.1.3.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *IJCAI*, 14(2), 1137–1145.