# Regularización

## Tutorial 5 – LASSO, ridge y elastic net

Luciana Azul Ramirez

PE1333 – Machine Learning para Economistas
Universidad de San Andrés

29 de octubre de 2026

# Fabricar un sesgo

$$ECM = \text{sesgo}^2 + \text{varianza} \qquad Y = X_1\beta_1 + X_2\beta_2 + u$$

- Sacar $X_2$ es imponer $\beta_2 = 0$. Si $\beta_2 \neq 0$ y $\delta_{21} \neq 0$, hay sesgo.
- Pero hay menos varianza, porque baja el $R_1^2$.
- Sacar variables conviene cuando la ganancia en varianza compensa la pérdida en sesgo$^2$.

# LASSO y ridge

$$R_l(\beta) = \sum_{i=1}^{n}(y_i - x_i'\beta)^2 + \lambda \sum_{s=2}^{p} |\beta_s| \qquad R_r(\beta) = \sum_{i=1}^{n}(y_i - x_i'\beta)^2 + \lambda \sum_{s=2}^{p} \beta_s^2$$

- 2 penalidades: ajuste y complejidad. El intercepto no se penaliza.
- Con $\lambda = 0$ es MCO. Con $\lambda \to \infty$, todos los $\beta_s$ van a cero.
- LASSO pone coeficientes exactamente en cero (*LASSO magic*). Ridge los achica a todos y no anula ninguno.

## Test de lectura

*T6.6. V o F: ridge es mínimos cuadrados ordinarios sujeto a la restricción de que los coeficientes tienen que ser mayores a cierto valor.*

# El caso simple: costo e ingreso marginal

Un solo predictor estandarizado, $\sum x_i^2 = 1$, de modo que $\hat{\beta} = \sum x_i y_i$. Si $\hat{\beta} > 0$:

$$\hat{\beta}_l = \text{máx}\left(\hat{\beta} - \lambda/2,\ 0\right) \qquad \hat{\beta}_r = \frac{\hat{\beta}}{1+\lambda}$$

- En LASSO, parado en cero, mover $\beta$ cuesta $\lambda$ por unidad, siempre lo mismo. Lo que baja la suma de cuadrados es cada vez más chico. Si en cero el costo ya le gana, conviene quedarse en cero.
- Pendiente de la función de penalidad: $-2\hat{\beta} + \lambda$.
- En ridge el costo marginal es $2\lambda\beta$, que en cero vale cero. Siempre conviene moverse un poco: la solución es interior.

## Test de lectura

*T5.9. V o F: en el caso simple estudiado, si la pendiente de la función de penalidad es positiva (hacia la derecha), la solución de LASSO es* $\hat{\beta}_l = 0$.

# Tachar, achicar o cortar

Si las $X$ no están correlacionadas entre sí y están estandarizadas, cada coeficiente se calcula por separado:

- Tachar (mejor subconjunto): deja $\hat{\beta}_j$ si supera un umbral y pone cero si no. Umbral duro.
- LASSO: resta $\lambda/2$ y corta en cero. Umbral suave.
- Ridge: divide por $1 + \lambda$. Achica en proporción.

## Test de lectura

*T5.5. ¿Por qué decimos que "tachar variables es una forma extrema de achicar sus coeficientes en el modelo"?*

# Vale la pena el sesgo?

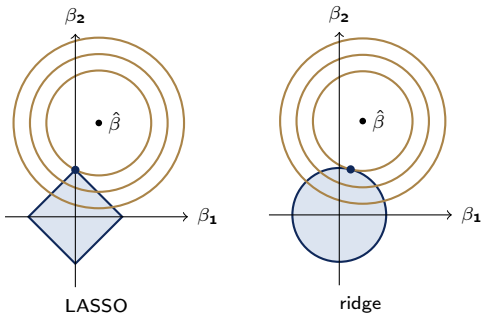
- Ridge contra MCO en el caso simple, bajo los supuestos clásicos: $E(\hat{\beta}_r) = \beta/(1+\lambda)$ y $V(\hat{\beta}_r) = \sigma^2/(1+\lambda)^2$.
- Si $\lambda < 2\sigma^2/\beta^2$, el ECM de ridge es menor que el de MCO.

## Test de lectura

*T5.18. V o F: en ridge siempre existe un valor de $\lambda$ para el cual su error cuadrático medio está por debajo del de MCO.*

# Como optimización restringida

- Minimizar la suma de cuadrados sujeto a $\sum |\beta_s| \leq C$ (LASSO) o a $\sum \beta_s^2 \leq C$ (ridge).
- Cada $\lambda$ tiene su $C$. Con $\lambda = 0$, $C = \infty$.
- El rombo tiene esquinas sobre los ejes. El círculo no.




## Test de lectura

*T6.7. Mirando el dibujo, ¿por qué ridge no elimina coeficientes y LASSO sí?*

# Elegir variables no es lo mismo que predecir

- Con predictores correlacionados, muchos modelos distintos predicen casi igual. LASSO elige uno, y con otra muestra puede elegir otro.
- Mullainathan y Spiess (2017) estiman LASSO en diez partes de una misma base: en cada una quedan variables distintas, con una calidad de predicción parecida.
- El $\lambda$ que elige cross validation es el mejor para predecir, y tiende a dejar adentro variables de más.
- Un coeficiente de LASSO no es un efecto: está achicado y su presencia depende de la muestra.

## Test de lectura

*T6.8. ¿Por qué decimos que LASSO resuelve tanto un problema de model selection como de mejorar el error cuadrático medio predictivo?*

# Elastic net

$$R_e(\beta) = \sum_{i=1}^{n}(y_i - x_i'\beta)^2 + \lambda_1 \sum_{s=2}^{p} |\beta_s| + \lambda_2 \sum_{s=2}^{p} \beta_s^2$$

- LASSO tiene dos problemas: con $p > n$ elige como máximo $n$ variables, y de un grupo muy correlacionado se queda con una sola, de manera arbitraria.
- Elastic net los resuelve: la parte LASSO elige predictores y la parte ridge estabiliza los grupos correlacionados.
- $\lambda_1$ y $\lambda_2$ se eligen por cross validation bidimensional.

# $\lambda$ en Python

- `Lasso(alpha)` minimiza $\frac{1}{2n}\sum(y_i - x_i'\beta)^2 + \alpha\sum|\beta_s|$. Entonces $\alpha = \lambda/2n$.
- `Ridge(alpha)`: $\alpha = \lambda$.
- `LogisticRegression(C)` va al revés: $C$ multiplica al ajuste, así que es la inversa de la penalidad. $C$ grande es poca penalidad.
- Por defecto, `LogisticRegression` ya penaliza con ridge y $C = 1$.

# Referencias


- Sosa Escudero, W. (2026). *Regularización y elección de modelos* y *Elastic net*. Clase 6. PE1333, UdeSA. Tests de lectura *Regularización A* y *B*.
- James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*, cap. 6.
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning*, 2.ª ed., sección 3.4.
- Mullainathan, S. y Spiess, J. (2017). Machine learning: An applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87–106.
- Meinshausen, N. y Bühlmann, P. (2006). High-dimensional graphs and variable selection with the lasso. *The Annals of Statistics*, 34(3), 1436–1462.
- Zou, H. y Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society, Series B*, 67(2), 301–320.